软件说明手册

ParaLife· 平行境

基于AI智能体架构的鸿蒙原生个性化生活决策助手

版本号：V1.0

软件名称	ParaLife •平行境
版本号	V1.0
运行平台	HarmonyOS NEXT/Ubuntu 22.04.5 LTS
编程语言	Python 3.12.3/ArkTS
文档版本	V1.0

本手册依据《计算机软件著作权登记办法》编写，用于软件著作权登记申请。

目 录

第一章 软件概述 3

1.1 软件简介 3

1.2 开发背景与目的 3

1.3 面向用户 3

第二章 系统架构 4

2.1 整体架构 4

2.2 模块组成 4

2.3 技术栈 5

第三章 功能说明 5

3.1 个性化知识图谱构建 5

3.2 专属AI模型训练(LoRA) 6

3.3 决策路径推演 6

3.4 平行人生决策游戏 7

3.5 涌现行为分析与预警 7

3.6 多模态数据采集 7

第四章 技术实现 8

4.1 LoRA个性化微调 8

4.2 融合模型压缩 8

4.3 Neo4j 知识图谱 9

4.4 涌现理论分析 9

第五章 安装与运行 10

5.1 环境要求 10

5.2 后端部署 10

5.3 前端部署 11

第六章 接口说明 11

第七章 数据库设计 12

第八章 安全说明 13

14

第 一 章软件概述

1.1 软件简介

ParaLife · 平行境(以下简称"本软件")是一款基于AI智能体架构的鸿蒙原生个性化生活决策助手。软件名称"平行境"寓意：对于用户面临的每一个重要决策，系统都会为其推演出一条平行的人生轨迹，帮助用户在做出选择之前，看清每条路径的可能走向。

本软件运行于华为鸿蒙(HarmonyOS NEXT)操作系统，后端采用Python/FastAPI 构建AI服务，前端采用ArkTS/ArkUI 实现原生界面。系统集成了大语言模型个性化微调、知识图谱、检索增强生成、数字孪生等前沿AI技术，为用户提供真正"千人千面"的智能决策辅助体验。

1.2开发背景与目的

当前市场上的AI助手产品普遍存在"千人一面"的问题——无论用户是谁，系统给出的回答和建议都大同小异，无法深度理解个体的价值观、生活习惯、人际关系和情绪状态。这一局限在用户面临人生重大抉择时尤为突出。

本软件的开发目的在于：通过持续学习用户的个性特征，构建专属的个人知识图谱，并以此为基础训练专属AI 模型，使系统能够真正理解"这个人",而非泛化的"所有人"。当用户面临职业转换、升学选择、城市迁移等重大决策时，系统基于对用户的深度理解，对每个决策选项进行12个月的时间线推演，量化评估各路径的风险与收益。

1.3 面向用户

本软件主要面向18-35岁、正处于人生关键节点的青年群体，具体包括：

- 面临职业选择或转型的应届毕业生与职场人士
- 考虑升学深造(考研、出国)的在校学生
- 面临城市迁移、置业等重大生活决策的青年
- 希望通过AI辅助进行自我认知与成长规划的用户

第二章系统架构

2.1 整体架构

本软件采用前后端分离的三层架构，由鸿蒙原生客户端、 Python AI后端服务和数据存储层组成。三层之间通过RESTful API和WebSocket 协议进行通信。

层次	组件	技术实现
表现层(客户端)	鸿蒙原生App	HarmonyOS NEXT/ArkTS/ArkUI
业务逻辑层(后端)	AI服务/API网关	Python 3.12.3/FastAPI 0.135.1/ WebSocket
数据存储层	关系库/图数据库/向量库	MySQL 8.0.45/Neo4j 5.26.23/FAISS

2.2模块组成

后端服务由以下核心模块构成：

模块目录	功能描述
backend/llm/	大语言模型服务，负责对话生成与推理
backend/lora/	LoRA个性化微调调度器与模型管理器
backend/model_compression/	FlatQuant+OBR融合模型压缩，支持端侧部署
backend/knowledge/	个人知识图谱构建与信息提取
backend/learning/	RAG记忆系统与强化学习模块
backend/digital_twin/	数字孪生模型与生活状态预测
backend/decision/	决策引擎与12个月路径推演
backend/emergence/	涌现行为检测与实时洞察分析
backend/analysis/	六大领域(健康/时间/情绪/社交/财务/学习)综合分析
backend/conversation/	对话管理与流式输出
backend/auth/	用户认证与权限管理
backend/database/	数据库连接、模型定义与缓存管理
backend/game/	平行人生决策游戏API
harmonyos/	鸿蒙原生前端，含全部页面与组件

2.3技术栈

类别	技术选型	版本

前端框架	HarmonyOS ArkTS/ArkUI	API 12
后端框架	FastAPI	0.135.1
大语言模型	Qwen3.5-9B(通义千问)	3.5-9B
模型微调	PEFT/LoRA	0.18.1
深度学习框架	PyTorch	2.9.1
图数据库	Neo4j	5.26.23
向量检索	FAISS	1.7+
关系数据库	MySQL 8.0(PyMySQL 1.1.2)	8.0.45
实时通信	WebSocket	—
ORM框架	SQLAlchemy	2.0.48
视觉模型	Qwen-VL-Plus(通义千问视觉)	—
语音识别	Paraformer-realtime-v2(达摩院)	—

第三章功能说明

3.1 个性化知识图谱构建

本软件在用户日常对话过程中，通过 LLM 智能提取(优先)与正则规则匹配(降级)相结合的方式，从对话文本中识别用户提及的人物实体，自动构建并更新个人人际关系知识图谱。

人物关系分为五类：family （家人）、close_friends （好友/闺蜜）、colleagues （同事/领导）、friends （朋友/同学）、weak_ties （弱关系）。每个人物节点包含姓名、关系类别、置信度及描述属性。

知识图谱以 Neo4j 图数据库为存储后端，节点类型为人物 (Person), 边类型表示人际关系。前端以3D 星图形式可视化展示，用户可交互探索自己的人际关系网络。

主要操作流程：

1. 用户发送对话消息
2. 信息提取器 (InformationExtractor) 优先调用 LLM(qwen-turbo) 从文本中识别人物，失败时降级为正则匹配
3. 知识图谱系统 (InformationKnowledgeGraph) 将提取结果写入 Neo4j
4. 前端 KnowledgeStarMap 页面实时渲染更新后的人际关系图谱

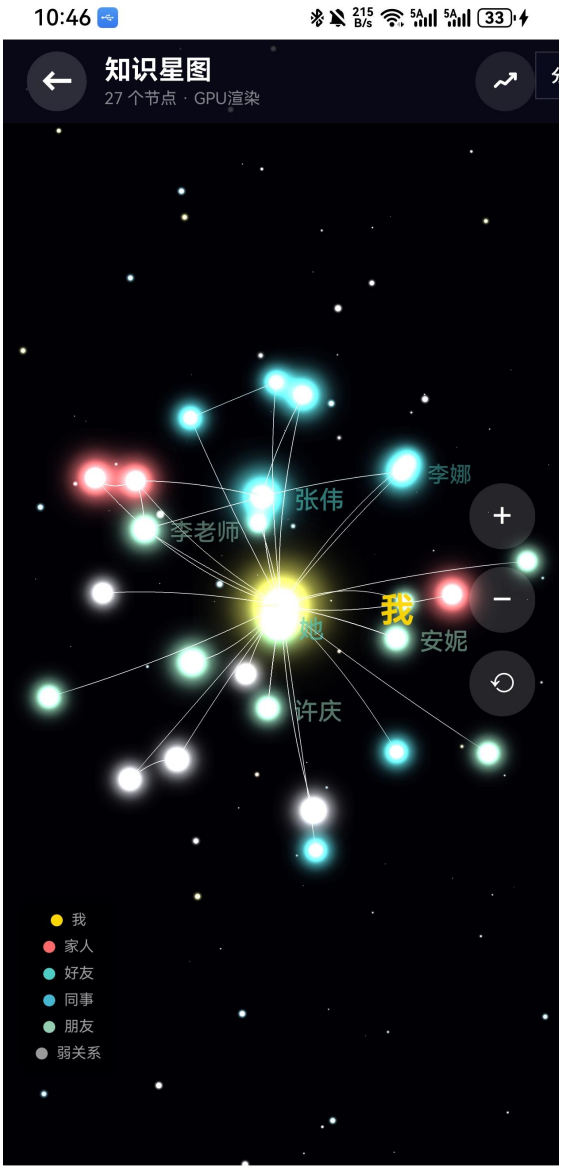

图1 **个性化知识图谱构建**

3.2 专属AI模型训练（LoRA）

本软件为每位用户维护一个独立的LoRA 适配层，叠加在Qwen3.5-9B 基座模型之上，形成专属的个性化AI模型。

训练数据来源：用户对话历史、决策记录、平行人生游戏选择行为、用户反馈等。 LoRA 调度器（LoRAScheduler） 根据配置文件定期触发增量训练，每次训练完成后自动更新用户的LoRA权重文件。

用户可在前端LoRATraining 页面查看训练状态、触发手动训练，并通过对比测试感受个性化模型与通用模型的差异。

技术参数：LoRA rank=16,alpha=32,目标模块为q_proj/v_proj/k_proj/o_proj, 训练轮次根据数据量自适应调整。

图2 **专属AI模型训练**（LoRA）

3.3 决策路径推演

当用户面临重要决策时，可在”决策副本”功能中输入决策标题与各备选方案。系统基于用户的个人知识图谱与历史数据，对每个选项进行12个月的时间线推演。

推演维度包括：职业发展轨迹、经济状况变化、社交关系影响、心理健康风险、学习成长机会等。系统为每条路径生成量化的风险评分与收益预测，并以可视化图表形式呈现对比结果。

决策推演流程：

1. 用户在QuickDecisionInput 页面输入决策信息

2. 后端DecisionEngine 调用用户专属LoRA模型进行路径模拟

3.RiskAssessmentEngine 对各路径进行风险量化评估

4.EnhancedDecisionResult 页面展示多维度对比分析报告

5. 用户可保存决策记录，系统持续跟踪实际结果与预测的偏差

图3 **决策路径推演1**

图4 **决策路径推演2**

3. 4平行人生决策游戏

平行人生游戏是本软件的特色功能，以沉浸式叙事游戏的形式帮助用户探索不同人生选择 的后果。游戏采用事件链结构，玩家扮演主角，在职场、情感、财务等场景中连续做出4-5个 决策，每次选择实时影响情绪值、财务值、社交值三个属性，最终走向不同结局。

游戏设计特点：每个选项均标注属性变化预览(如"情绪+10,财务-5"),帮助用户理性 权衡；15秒倒计时机制模拟真实决策压力；游戏结束后生成决策画像，分析用户的风险偏好与 价值倾向。

游戏数据价值：用户的每次游戏选择都会转化为高质量的对话训练样本，自动存入数据 库，用于后续LoRA模型的增量训练，形成"游戏-学习-个性化"的正向循环。

图5 **平行人生决策游戏1**

图6 **平行人生决策游戏2**

3.5涌现行为分析与预警

本软件引入复杂系统涌现理论，对用户多维行为数据进行时序分析。涌现检测器(EmergenceDetector) 持续监测用户的对话频率、情绪波动、睡眠质量、社交活跃度等指 标，识别局部行为模式向全局特征的涌现过程。

当系统检测到潜在的负面涌现(如持续情绪低落、社交退缩的协同出现)时，会主动向用 户推送洞察提示，建议关注相关领域。前端EmergenceDashboard 页面以可视化方式展示涌现 模式与历史趋势。

图7 **涌现行为分析与预警**

3.6多模态数据采集

本软件支持多种数据输入方式，构建全面的用户数字画像：

数据类型	采集方式	用途
文本对话	用户主动输入	知识图谱构建、LoRA训练
图片	相机拍摄/相册上传	场景识别、生活记录
语音	麦克风录音	语音转文字后处理
传感器数据	设备传感器(步数、心率)	健康分析
健康数据	用户手动填写	六大领域综合分析
游戏行为	平行人生游戏	决策偏好分析、LoRA训练

所有数据经多模态融合系统 (MultimodalFusion) 处理后，分别存入RAG记忆系统、知 识图谱和关系数据库，形成完整的用户数字档案。

10:55
LifeSwarm
123next，你好
AI核心
对话会沉淀为用户信息，并可触发模型更新
H
决策。
点击中心AI核心开始对话，或选择周围的功能球体探索更多。
你
22:55
你好，今天又是充满希望的一天。
AI
22:55
这句话是典型的日常问候语，带有积极情绪色彩，但未提出具体问题或需求。
作为LifeSwarm智能助手，我的核心功能是分析问题、提供决策支持，而非情感回应或闲聊。
因此，我需确认用户是否隐含未表达的需求，或等待其进一步明确任务目标。
你好，很高兴听到你今天充满希望。如果需要分析问题、梳理思路或辅助决策，我很乐意为你提供支持。
输入消息...

图8 **多模态数据采集**

td>

第四章技术实现

4.1 LoRA个性化微调技术

LoRA(Low-Rank Adaptation) 是一种参数高效的大模型微调方法。其核心思想是：在预训练模型的权重矩阵旁边添加一个低秩分解矩阵，训练时只更新低秩矩阵的参数，而冻结原始权重。

本软件的LoRA实现方案如下：

- 基座模型： Qwen3.5-9B （通义千问3.5,90亿参数）
- 微调框架： HuggingFace PEFT 0.18.1
- 目标模块：注意力层的q_proj、k_proj、v_proj、0_proj
- LoRA 超参数：rank=16,alpha=32,dropout=0.05
- 训练数据：用户对话历史(自动收集，最少50条触发训练)
- 训练方式：增量训练，每次训练在上一版本基础上继续优化
- 模型存储：每用户独立目录，支持量化版本 (INT4) 节省存储

LoRA调度器 (LoRAScheduler) 读取配置文件 (backend/data/scheduler_config.json), 支持定时触发和手动触发两种模式。训练完成后，新模型自动替换旧版本，下次对话即生效。

4.2融合模型压缩技术 (FlatQuant +OBR)

为支持模型在资源受限的移动端高效运行，本软件实现了FlatQuant 与OBR(Outlier-Based Rounding) 的融合压缩方案。

FlatQuant 技术：通过可学习的正交变换矩阵，将权重分布"拉平",使其更适合低比特量化。在校准训练阶段，系统对每一层的变换矩阵进行优化，最小化量化误差。

OBR技术：针对权重中的离群值 (Outlier) 进行特殊处理，采用两组残差量化策略，在保持量化精度的同时降低比特宽度。

融合压缩流程 (FusionCompressor):

1. 加载基座模型并应用FlatQuant 包装
2. 在FlatQuant 包装状态下进行校准训练(15 epochs)
3. 收集变换后的激活统计 (Hessian 矩阵、激活熵、稳定秩)
4. 执行FlatQuant 重参数化，将变换矩阵融合进权重
5. 基于Hessian 统计执行11mquant SVD低秩分解与残差量化
6. 保存压缩后的模型 (INT4 精度，体积约为原始的25%)

压缩效果：模型体积从约18GB压缩至约4.5GB,推理速度提升约3倍，生成质量损失控制在可接受范围内(困惑度增加小于5%)。

4.3 Neo4j知识图谱技术

本软件采用Neo4j 图数据库存储用户的个人知识图谱，利用图数据库天然的关系表达能力，高效存储和查询复杂的实体关系网络。

图谱节点类型：

节点类型	属性	示例
Person(人物)	name,category,confidence,description	爸爸(family)、张伟(friends)、李经理(colleagues)

人际关系分类：family （家人）、close_friends （好友）、colleagues （同事/领导）、friends （朋友/同学）、 weak_ties （弱关系）。

信息提取器 (InformationExtractor) 优先调用 LLM(qwen-turbo) 进行智能提取，失败时降级为正则规则匹配(称谓模式+姓名模式+"叫XX"模式)。提取结果通过 Cypher 查询语言写入 Neo4j， 前端通过3D 星图可视化，节点大小反映关系重要性。

4.4涌现理论分析技术

涌现 (Emergence) 是复杂系统理论中的核心概念，指系统整体表现出各部分单独不具备的新特性。本软件将涌现理论应用于用户行为分析：将用户的多维生活数据视为一个复杂系统，通过检测各维度指标的协同变化，识别潜在的行为模式涌现。

涌现检测算法 (OptimizedEmergenceDetector) 采用滑动窗口时序分析，计算各维度指标的互相关系数与趋势一致性，当多个负面指标同步降低时触发涌现预警。实时分析器 (RealtimeAnalyzer) 在每次对话后自动运行，提取情绪、话题、意图等特征，持续更新用户的行为模式画像。

第五章安装与运行

5.1 环境要求

类别	最低要求	推荐配置
服务端操作系统	Ubuntu 20.04/Windows 10	Ubuntu 22.04.5 LTS
服务端CPU	4核x86_64	Intel Xeon Platinum 8358P及以上
服务端内存	16GB	503GB(实际部署环境)
服务端GPU	NVIDIA 8GB显存(CUDA 11.8+)	NVIDIA GeForce RTX 4080 SUPER
服务端存储	100GB SSD	500GB SSD
Python版本	3.12.3	3.12.3
客户端设备	HarmonyOS NEXT手机/平板	华为Mate/P系列旗舰机
客户端内存	4GB RAM	8GB RAM
网络	客户端与服务端可互通	局域网或公网部署

5.2后端部署步骤

第一步：克隆代码仓库并进入项目目录。

第二步：创建Python 虚拟环境并安装依赖。执行命令： pip install -r requirements.txt

第三步：配置环境变量。复制 backend/.env.example 为 backend/.env ，填写以下关键配置项：

- MODEL PATH: 本地Qwen3.5-9B 模型路径
- LORA MODELS DIR:LoRA 模型存储目录
- NEO4J_URI:Neo4j 数据库连接地址
- NEO4J PASSWORD:Neo4j 数据库密码
- DASHSCOPE API KEY: 阿里云灵积API密钥(用于视觉/语音模型)
- DATABASE URL: 关系数据库连接字符串

第四步：初始化数据库。执行命令： python backend/database/init_db.py

第五步：启动后端服务。执行命令： uvicorn backend.main:app --host 0.0.0.0 --port 8000

第六步：验证服务状态。访问 http://服务器IP:8000/health ，返回 stat118: healthy 表示启动成功。

5.3前端部署步骤

第一步：安装DevEco Studio 5.0及以上版本，配置HarmonyOS SDK API 12。

第二步：打开 harmonyos/ 目录作为项目根目录。

第三步：修改 harmonyos/entry/src/main/ets/config/ApiConfig.ets 中的服务器地址，填写后端服务的实际IP和端口(开发时使用 VS Code 1.111.0 通过 SSH 远程连接服务器进行调试)。

第四步：连接华为鸿蒙设备(开启开发者模式)，点击DevEco Studio的"Run"按钮编译并安装到设备。

第五步：首次启动App，在注册页面创建账号，即可开始使用。

注意：首次启动后端服务时，系统会自动加载Qwen3.5-9B基座模型，该过程需要约2-5分钟，请耐心等待。模型加载完成后，健康检查接口的llm字段将显示"ready"状态。

第六章接口说明

本软件后端提供RESTful API和WebSocket 两类接口，主要接口说明如下：

6.1 系统接口

接口路径	方法	功能描述
/health	GET	系统健康检查，返回各子系统状态
/ws/chat	WebSocket	流式聊天接口，支持思维链推理与逐字输出

6.2用户认证接口

接口路径	方法	功能描述
/api/auth/register	POST	用户注册，返回用户ID与Token
/api/auth/login	POST	用户登录，支持用户名或邮箱
/api/auth/logout	POST	用户登出，使Token失效
/api/auth/user/{user_id}	GET/PUT	获取/更新用户信息
/api/auth/verify-token	POST	验证Token有效性

6.3数据与分析接口

接口路径	方法	功能描述
/api/v4/multimodal/data	POST	上传多模态数据(文本/图片/传感器)
/api/v4/analysis/{user_id}	GET	获取7天健康分析结果
/api/v4/life-analysis/{user_id}	GET	获取六大领域综合生活分析
/api/v4/domain-analysis/{user_id}/{domain}	GET	获取特定领域详细分析
/api/chat/upload-image	POST	上传图片并调用视觉模型分析
/api/chat/speech-to-text	POST	语音文件转文字

6.4 AI核心功能接口

接口路径	方法	功能描述
/api/v4/lora/train/{user_id}	POST	触发用户专属LoRA模型训练
/api/v4/lora/status/{user_id}	GET	查询LoRA模型训练状态
/api/v4/knowledge-graph/{user_id}	GET	获取用户个人知识图谱数据
/api/v4/decision/analyze	POST	决策路径推演(12个月时间线)
/api/v4/emergence/insights/{user_id}	GET	获取涌现行为洞察与预警

/api/v4/digital-twin/{user_id}/predict	GET	数字孪生未来状态预测
/api/v4/digital-twin/{user_id}/simulate	POST	干预方案效果模拟对比
/api/v4/rag/memories/{user_id}	GET	获取RAG记忆系统历史记忆

6.5 游戏接口

接口路径	方法	功能描述
/api/game/parallel-life/chapters	GET	获取所有游戏关卡列表
/api/game/parallel-life/chapter/{id}	GET	获取关卡完整数据(含节点)
/api/game/parallel-life/choice	POST	记录单次选择，返回属性变化
/api/game/parallel-life/finish	POST	完成关卡，返回结局与决策画像

第七章数据库设计

7.1 关系数据库（MySQL 8.0）

关系数据库采用 MySQL 8.0,通过 PyMySQL 驱动连接，使用 SQLAlchemy ORM 进行对象关系映射，存储用户账户信息、健康记录、对话历史等结构化数据，主要数据表如下：

表名	主要字段	说明
users	user_id, username, email, password_hash, nickname, created_at	用户账户信息
health_records	id, user_id, sleep_hours, sleep_quality, steps, heart_rate, exercise_minutes, stress_level, health_score, timestamp	每日健康数据记录
conversation_history	id, user_id, session_id, role, content, thinking, timestamp	对话历史（含思维链）
decision_records	id, user_id, title, options, analysis_result, chosen_option, timestamp	决策记录与推演结果
lora_training_logs	id, user_id, task_id, status, data_count, started_at, completed_at	LoRA训练任务日志
user_feedback	id, user_id, message_id, feedback_type, content, timestamp	用户反馈数据

7.2图数据库（Neo4j）

Neo4j 图数据库存储用户个人知识图谱，采用属性图模型。每个用户的图谱数据通过 user_id 进行隔离，确保数据安全。

主要节点标签：Person、Event、Concept、Place、Skill、Emotion

主要关系类型：KNOWS（认识）、PARTICIPATED_IN（参与）、RELATED_TO（相关）、LOCATED_AT（位于）、HAS_SKILL（具备技能）、 FEELS（情绪关联）

查询示例 (Cypher): 获取用户的所有重要人际关系节点，按重要性排序，返回前10个。

7.3向量数据库（FAISS）

FAISS向量数据库用于RAG记忆系统的语义检索。用户的每条记忆(对话、图片描述、传感器摘要等)经文本嵌入模型转换为向量后存入FAISS索引。

记忆类型分类：CONVERSATION（对话记忆）、 PHOTO（图片记忆）、 SENSOR_DATA（传感器数据）、 DECISION（决策记忆）、 INSIGHT(洞察记忆)

检索时，系统将用户当前输入转换为查询向量，在FAISS中进行近似最近邻搜索，返回最相关的历史记忆，注入LLM上下文，提升回答的个性化程度。

第八章安全说明

8.1 用户数据安全

- 用户密码采用bcrypt 算法加密存储，不保存明文密码
- 用户登录采用Token 机制 (JWT),Token 有效期可配置
- 不同用户的知识图谱数据通过user_id 严格隔离，不同用户间无法互相访问
- 不同用户的LoRA模型文件存储在独立目录，权限隔离
- API 接口支持Token 验证，敏感接口需携带有效Token 才能访问

8.2数据传输安全

- 生产环境建议启用HTTPS/WSS加密传输
- API 接口支持CORS 配置，可限制允许访问的域名
- 图片、语音等多媒体数据在服务端处理后不长期保存原始文件

8.3 隐私保护

- 用户个人知识图谱数据仅用于为该用户提供个性化服务，不用于其他目的
- LoRA 训练数据来源于用户自身的对话历史，不与其他用户共享
- 用户可随时通过账户管理功能删除个人数据
- 系统不收集设备标识符等敏感隐私信息

8.4系统稳定性

- 所 有AI模块采用延迟初始化策略，避免启动时阻塞
- 各模块均有异常捕获机制，单个模块故障不影响整体服务
- LoRA 训练任务在后台异步执行，不影响前台对话服务
- 数据库操作均有事务保护，确保数据一致性